## TD: Représentation des flottants et norme IEEE754

				ruser				_			_		u	e talli	e c	lan	SI	a m	en	IOII	e c	ur	ı Oi	aı	maı	eur	? ٢	our
	Sur 32 bits, une idée est de prendre 1 bit pour écrire le signe, de réserver 8 bits pour coder la partie entière (non signée) et le reste pour coder la partie fractionnaire (après la virgule)																											
Sig	ne	Р	artie	e entiè	ere										Pa	rtie	fra	actic	nn	aire	)							
•	<ol> <li>De combien de bits sera constitué la partie fractionnaire ?</li> <li>L'idée la plus naïve est de coder la partie entière comme nous l'avons fait avec les entiers.</li> <li>Quelle est la partie entière la plus grande que l'on peut écrire sur les 8 bits réservés ?</li> <li>Cela vous semble-t-il suffisant ?</li> </ol>																											
				même te rep				•				•							•	ue	vo	us	poı	uri	riez	atte	eino	dre
On se retrouve avec des nombres bien trop petits et/ou une précision assez limitée Essayons d'améliorer cela !																												
3) Écrivez les nombres 3457064,21 et 0,0321 sous forme de notation scientifique.																												
	-			n que ère g																								$\mathbb{Z}.$
4)	<ul> <li>4) a. À votre avis, que devient la notation mantisse-exposant en base 2?</li> <li>b. À l'aide de puissance de 2, écrivez les nombres 110<sub>2</sub>, 1001<sub>2</sub> puis 0,0101<sub>2</sub> sous forme mantisse-exposant. <i>Pour simplifier, on écrira l'exposant de la puissance de 2 en base 10.</i></li> <li>c. Que pouvez-vous en déduire sur la valeur de la mantisse M ? Est-il nécessaire de la stocker entièrement en base 2 ?</li> <li>d. Proposez un procédé de stockage basé sur la notation mantisse-exposant. On s'aidera du tableau ci-dessous :</li> </ul>																											

e. Avec votre procédé de stockage, proposez la notation binaire sur 32 bits de -66,825.

Là, on se dit qu'on est plutôt beau gosse. On a même réussi à économiser un bit dans la mantisse pour aller à une précision de  $2^{-23}$  (comme avant en gros...).

- 5) Quel problème rencontre-t-on si on essaie de donner la notation binaire sur 32 bits de 0,125 ?
- 6) Sur 8 bits, avec le décalage, quel exposant écrire afin de coder  $2^0$  ?  $2^1$  ?  $2^{128}$  ?

## L'ensemble de ces spécifications est appelée norme IEEE-754

- 7) Soit le nombre "-10,125" en base 10. Représentons-le en simple précision :
  - **a.** Écrire en base 2 le nombre  $10,125_{10}$ .
  - b. Écrire ce nombre sous forme mantisse-exposant puis décaler l'exposant de 127 unités.
  - c. Écrire l'exposant en base 2.
  - d. Conclure sur la représentation du nombre les 32 bits
  - e. Écrire le nombre obtenu en hexadécimal

## C'est beau la norme IEEE754!

- 8) Représenter le nombre "0,1" sous la norme IEEE754.
- 9) Soit le nombre flottant au format simple précision :

00111101110011001100110011001100.

Trouvez la représentation en base 10 de ce nombre.

10) Déterminez la représentation au format simple précision d'un tiers (1/3) en binaire et en hexadécimal.

## Pour aller plus loin:

- En notation mantisse-exposant, il est impossible de représenter le nombre 0. Pour pallier à ce problème, l'exposant 0 est réservé. Lorsque l'exposant vaut 0, nous pouvons avoir deux valeurs : +0 ou -0 (en fonction du signe).
- $\diamond$  De même, l'exposant 255 est réservé pour des valeurs spéciales telles  $+\infty, -\infty$  ou NaN.

Lorsque, en simple précision, le nombre cherché est en-dehors de  $[-1.7 \times 10^{38}; 1.7 \times 10^{38}]$ , on atteint un infini : on met l'exposant à 255 et la mantisse à 0 pour signaler cela.

Lorsque l'on réalise une opération interdite (division par 0,  $\sqrt{-1}\,\dots$ ), on renvoie une valeur spéciale appelée **NaN** (**N**ot **a N**umber) : on met l'exposant à 255 et la mantisse différente de 0 pour signaler ce cas.